

1 2



9 0

FACULDADE DE
CIÊNCIAS E TECNOLOGIA
UNIVERSIDADE D
COIMBRA

Análise e Transformação de Dados

Licenciatura em Engenharia Informática
2024

Relatório | Projeto

Docentes:

Ismael José Fervença de Jesus

Alberto Jorge Lebre Cardoso

Discentes:

Luís Miguel Ferreira Vaz (2022214707)

Eugénia Conceição Martins de Oliveira (2020218769)

Índice

Ponto 1.....	3
Ponto 2.....	3
Ponto 3.....	3
Ponto 4.....	4
Ponto 5.....	5
Ponto 6.....	6
Ponto 7.....	8
Ponto 8.....	10
Ponto 9.....	12
Ponto 10.....	15
Ponto 11.....	16
Ponto 12.....	19
Ponto 13.....	24
Ponto 14.....	25
Conclusão.....	26

Explicação do Procedimento Adotado

Ponto 1

Relativamente ao processo de importação dos sinais de áudio criou-se primeiramente uma variável '*folder*' que armazena o encaminhamento para onde se encontram todos os ficheiros de áudio relativos à pessoa nº23. De seguida utilizou-se as funções '*fullfile*' e '*dir*' de forma a organizar os ficheiros com a extensão ".wav" em uma lista (*audio_files*). Posteriormente utilizou-se um ciclo '*while*' que vai iterar sob todos os ficheiros, para cada ficheiro aplicou-se a função '*audioread*' que retorna os dados da amostra (*y*) e a taxa de amostragem a cada 1 segundo (*Fs*).

Ponto 2

Para a representação gráfica dos exemplos relativos aos sinais importados, calculou-se primeiramente o tempo total de cada ficheiro, dividindo o número de amostras recolhidas (*length(y)*) pela taxa de amostragem (*Fs*), de seguida utilizou-se a função '*linspace*' de forma a obter um vetor com intervalos de tempo iguais entre si ('*t*'). Devido ao facto de os ficheiros estarem ordenados por dígito, e que por estarmos a utilizar um ciclo '*while*' sabemos que as primeiras 50 iterações serão relativas ao dígito "0", as iterações 51 a 100 serão relativas ao dígito "1" e assim sucessivamente. Logo utilizou-se a condição (*mod(n,50)==0*), com *n* a ser o número respetivo à iteração em questão, de forma a detetar a mudança de dígito, e assim cada vez que o ciclo entrou nesta condição contruiu-se o gráfico de forma a representar a onda de som do dígito em questão. Para a construção do gráfico utilizou-se a função '*plot*' que recebe o array '*y*' que contém os valores para as amostras obtidas proveniente do *audioread* e o array '*t*' que foi calculado anteriormente.

Ponto 3

Para distinguir os dígitos, seleccionámos características temporais significativas, entre os quais energia total, amplitude máxima, mínima e média, desvio padrão da amplitude e energia por intervalos. Inicialmente, otimizamos essa distinção utilizando as funções '*remove_silence*', '*normalize_amplitude*' e '*adjust_duration*'. A primeira elimina o silêncio inicial, usando um limiar de energia para preservar informações relevantes. A normalização da amplitude padroniza a escala dos gráficos, enquanto o ajuste da duração uniformiza a extensão do sinal para a duração desejada.

A escolha dos parâmetros, como 0.15 para a remoção de silêncio e 0.6 para a duração desejada, foi validada através da análise dos gráficos resultantes, visando manter as informações cruciais sem perdas.

Dada a variabilidade nas características temporais devido a diversas influências, optamos por calcular médias para cada característica por dígito, agrupando 50 amostras para representar um dígito. Esta abordagem permitiu-nos reduzir a variabilidade entre sinais, facilitando a análise individual de cada dígito.

Para analisar as variações temporais, o sinal é dividido em janelas de tamanho definido por 'window_size' e de seguida é calculada a energia para cada janela. Essa metodologia proporciona uma representação mais estável e informativa dos dígitos, considerando a diversidade nas pronúncias, velocidades de fala e qualidade das gravações.

Ponto 4

As três características selecionadas para a análise dos dígitos - energia total, amplitude média e desvio padrão - foram escolhidas com base na capacidade de fornecer informações discriminativas sobre os diferentes dígitos.

- Energia Total: Esta medida reflete a intensidade global do sinal de áudio. Ao analisar o gráfico “Scatter Plot em 3D”, é perceptível a diferença na separação entre os pontos correspondentes aos diferentes dígitos, o que indica que a energia total é um bom critério para a identificação dos dígitos. Esta separação é ainda mais evidente no gráfico “boxplot”, onde os diferentes grupos de dígitos apresentam distribuições claramente distintas de energia total.
- Amplitude Média: Esta característica fornece a intensidade média do sinal de áudio ao longo do tempo. No scatter plot, à semelhança da Energia Total, podemos observar que cada dígito tem valores distintos, o que contribui para a utilização da amplitude média como característica discriminativa. Na análise do gráfico “boxplot” podemos verificar que existem variações significantes e que se revelam úteis para a distinção entre dígitos.
- Desvio Padrão: O desvio padrão indica a variação dos valores da amplitude ao longo do sinal de áudio. Observamos que diferentes dígitos apresentam diferentes níveis de variação na intensidade, o que facilita a distinção entre os mesmos.

Por exemplo: ao analisarmos o gráfico “ScatterPlot em 2D” na visão abaixo representada (Eixo X – Amplitude Média, Eixo Y – Energia Total), podemos perceber, com a conjugação dos 2 critérios utilizados, que os pontos relativos aos dígitos 5, 6 e 8 tendem a acumular-se nas zonas para que os valores de amplitude média e energia total são mais baixos, enquanto os pontos que representam os dígitos 1,2,7 e 9 estão situados na região do gráfico relativa a valores de amplitude média e energia total mais elevados.




Figura 1- Boxplot das características temporais




Figura 2- Scatter plot das características temporais

As características selecionadas foram fundamentais para a análise dos dígitos, fornecendo informações valiosas sobre a intensidade, consistência e a variação do sinal associada a cada dígito.




Figura 3- Scatter plot 2D das características temporais




Figura 4- Scatter plot 3D das características temporais

Ponto 5

De forma a organizar melhor a informação decidimos criar uma matriz com 50 linhas (número de amostras por dígito) e com número de colunas igual ao número de frequências existentes. Desta forma temos a informação organizada por dígito, o que nos facilita posteriormente a obtenção da mediana e dos quartis dado que só necessitamos de aplicar as funções “quantile” e “median” à cada coluna da matriz. Quando atingimos a condição de mudança de dígito, limpamos a matriz de forma a preparar a próxima iteração que ira acomodar os valores para o dígito seguinte.




Figura 5- Gráficos das Medianas e Quartis dos dígitos de 0 a 9

Relativamente ao tratamento da informação, primeiramente calculou-se a Transformada de Fourier discreta aplicando ao array de valores devolvidos pelo audioread, (y), a função “fft”. De seguida dividiu-se o array de valores devolvido pelo número de amostras de forma a normalizar o sinal. Devido a só nos interessar analisar as frequências positivas e sabendo que as frequências negativas se encontram na

segunda metade do sinal, ao inserir os resultados na matriz vamos apenas inserir até atingirmos a metade.

Ponto 6

→ Gráficos do sinal de áudio:

Para a realização do ponto 6, selecionou-se as janelas Hamming, Blackman e Kaiser. A seleção de janelas tem um papel importante na determinação dos resultados gerais. O papel principal das janelas é minimizar os efeitos do fenômeno de Gibbs, este fenômeno ocorre quando usamos a série de Fourier para representar funções com descontinuidades, o que resulta na existência de oscilações e pequenas distorções perto dos pontos de descontinuidade.

A janela de Hamming é uma janela de corte suave que atenua as frequências no espectro do sinal, o que ajuda a melhorar a resolução das frequências tornando as bordas do sinal mais suaves.




Figura 6- Sinal Sonoro original




Figura 7- Sinal Sonoro após aplicada a janela Hamming




Figura 8- Sinal Sonoro após aplicada a janela Blackman




Figura 9- Sinal Sonoro após aplicada a janela Kaiser

Por outro lado, a janela de Blackman permite uma melhor atenuação dos lóbulos laterais em relação a janela de Hamming no que resulta a existência de uma melhor supressão de vazamentos espectrais e uma redução mais suave das frequências fora do intervalo principal do sinal.

Já a janela de Kaiser é uma janela flexível que recebe um parâmetro que permite ajustar a largura do lóbulo principal e o nível de atenuação das frequências laterais. Acaba por ser uma janela intermédia entre as janelas de Hamming e Blackman.

Os gráficos abaixo exibidos representam o sinal sonoro original (figura 6) e após serem aplicadas as respetivas janelas (figuras 7, 8 e 9). Através da análise dos gráficos, podemos concluir que as janelas de Hamming, Blackman e Kaiser tendem a atenuar a amplitude nos extremos do sinal em comparação com o gráfico original.

→ Gráficos da mediana e quartis:

Os seguintes gráficos apresentam a variação dos valores da mediana e do primeiro e terceiro quartis para cada dígito, após a aplicação das janelas referidas anteriormente. Ao comparar as janelas entre si é possível concluir que existem variações nos valores das amplitudes.

Ao compararmos a janela original com a janela de Hamming, verificamos uma notória variação dos valores de amplitude para o dígito 4, sendo notório que na janela de Hamming os valores referentes a este dígito atingem valores superiores.

Ao compararmos a janela original com a janela de Blackman é de realçar que em dígitos como o 6 e o 8 são atingidos valores superiores na janela de Blackman, no entanto ao analisarmos os resultados obtidos para os dígitos 1 e 9, o contrário também se verifica, atingindo estes dígitos valores inferiores quando comparados à janela original.

Ao compararmos a janela original com a janela de Kaiser, usando um $\beta = 5$, podemos concluir que existem diferenças nos gráficos apresentados, especificamente nos gráficos dos dígitos 4, 5 e 8 onde são atingidas maiores amplitudes do que na representação original.




Figura 10- Gráfico das medianas e quartis após aplicada a janela de Hamming




Figura 11- Gráfico das medianas e quartis após aplicada a janela de Blackman




Figura 12- Gráfico das medianas e quartis após aplicada a janela de Kaiser

Ponto 7

As características espectrais são medidas que descrevem como a energia do sinal de áudio está distribuída ao longo do espectro da frequência. Estas medidas são úteis para interpretar as propriedades fundamentais de um sinal de áudio e são utilizadas em diversas aplicações, incluindo o reconhecimento da fala.

No nosso estudo calculámos **máximos espectrais** (posição e amplitude), **médias espectrais**, **spectral edge frequency** e **entropia espectral**.

→ Máximos Espectrais:

Os máximos espectrais referem-se aos picos de amplitude no espectro de frequência de um sinal de áudio. Estes picos indicam as frequências dominantes presentes no sinal, enquanto as amplitudes indicam a intensidade dessas frequências. Dígitos com características vocais distintas podem apresentar picos em diferentes frequências e com diferentes amplitudes, o que os torna discrimináveis uns dos outros. A identificação dos máximos é realizada através da aplicação da Transformada de Fourier ao sinal, seguida pela identificação de picos na magnitude do espectro resultante.

A escolha da distância mínima de 100Hz entre os picos, na função *findpeaks*, deveu-se à necessidade da redução de picos sem relevância para a análise.

→ Médias Espectrais:

As médias espectrais representam a média das amplitudes das frequências em todo o espectro do sinal de áudio. Esta medida dá-nos uma visão geral da distribuição da energia espectral ao longo das frequências. Dígitos com padrões vocais diferentes tendem a ter distribuições de energia diferentes em frequência, refletindo-se em médias espectrais distintas. Portanto, esta

característica permite-nos identificar padrões consistentes de distribuição de energia que podem ajudar na distinção dos dígitos.

No contexto deste código, as médias espectrais são obtidas calculando-se a média das amplitudes presentes no espectro de magnitude, que é derivado da aplicação da Transformada de Fourier ao sinal de áudio. Cada valor de média espectral representa, portanto, uma medida média da intensidade das frequências presentes no sinal.

→ Spectral Edge Frequency:

A Spectral Edge Frequency (SEF) é a frequência na qual uma determinada percentagem da energia espectral total é alcançada. Esta medida fornece informações sobre a distribuição de energia numa frequência do sinal de áudio. Dígitos com características vocais únicas tendem a distribuir a sua energia espectral de maneira diferente, resultando em valores de SEF distintos. Portanto, ao analisar o SEF, podemos identificar que frequências contribuem significativamente para a energia total do sinal, útil na diferenciação entre os dígitos.

Para o cálculo do SEF, primeiramente é obtida a energia acumulada (`cumulative_power`) ao longo das frequências presentes no sinal de áudio, utilizando a função `cumsum()`. Em seguida, a energia total (`total_power`) do sinal é calculada somando todas as amplitudes espectrais. Finalmente, a Spectral Edge Frequency é determinada encontrando a frequência na qual 90% da energia total é alcançada. Isto é feito procurando na matriz `cumulative_power` o índice correspondente ao primeiro valor que excede ou é igual a 90% da energia total, e associando a frequência desse índice no vetor de frequências.

→ Entropia Espectral:

A entropia espectral é uma medida de distribuição de energia espectral no sinal de áudio, que quantifica a uniformidade ou a dispersão da energia. Dígitos com características vocais distintas podem ter distribuições de energia espectral diferentes, resultando em diferentes níveis de entropia espectral. Portanto, esta medida ajuda a identificar padrões de distribuição de energia que são únicos para cada dígito.

Para o seu cálculo, é obtida a probabilidade de ocorrência de cada amplitude espectral, dividindo as amplitudes pela soma de todas as amplitudes espectrais. Em seguida, é calculada a entropia espectral como a soma do produto entre a probabilidade de ocorrência de cada amplitude e o logaritmo de base 2 dessa probabilidade. Este cálculo é realizado para todas as amplitudes espectrais presentes no sinal de áudio.

No ponto que se segue discriminamos os resultados obtidos, assim como a explicação de cada *plot* obtido.

Ponto 8

As características que calculámos no ponto anterior foram apresentadas em plots, de maneira a conseguir analisar o sinal e identificar as três características que se destacam como os melhores discriminadores.

Ao analisar os máximos espectrais (posição e amplitude) dos dígitos, observamos que o dígito 5 apresenta o maior pico em termos de frequência, seguido pelos dígitos 4, 1 e 7. Quanto à amplitude do pico máximo, os dígitos 9, 1, 3 e 0 exibem os valores mais altos, seguidos pelo dígito 2, 5 e 7. Observando especificamente o dígito 5, este tem o pico na posição mais alta, mas não tem a amplitude mais alta, o que sugere que, embora essa frequência específica seja proeminente no dígito 5, a sua intensidade não é a mais elevada em comparação com outros dígitos. Essa disparidade entre a posição e a amplitude do pico pode refletir diferenças na pronúncia ou entoação, resultando em padrões espectrais distintos.

Com base nas diferenças significativas observadas entre os diferentes dígitos, podemos afirmar que esta é uma característica promissora para a discriminação entre sinais.




Figura 13- Scatter e Boxplot do Máximo Espectral

Ao analisar os gráficos das médias espectrais, apresentados abaixo, podemos concluir que é uma boa característica, apesar de não ser a melhor para discriminar um sinal. Embora se repare a diferença entre cada dígito, alguns dos dígitos têm valores muito próximos.




Figura 14- Scatter e Boxplot da Média Espectral




Figura 15- Scatter e Boxplot do SEF

A análise dos gráficos que representam a entropia espectral revela uma distribuição distinta entre os dígitos. Os dígitos 6 e 7 destacam-se por apresentar a maior entropia, indicando uma distribuição de energia espectral mais uniforme em comparação com os outros dígitos. Os dígitos 5, 3, 0, 8 e 9 surgem com valores de entropia aproximadamente iguais, refletindo uma distribuição de energia semelhante entre esses dígitos. Por outro lado, os dígitos 1, 2 e 4 apresentam entropias mais baixas, indicando uma distribuição de energia mais concentrada em frequências específicas. Essa observação sugere que a entropia espectral pode ser uma característica útil na diferenciação dos dígitos, especialmente quando se trata de dígitos com entropias significativamente distintas. No entanto, para os dígitos com valores de entropia semelhantes, pode ser mais desafiador distinguir com base apenas nessa característica.




Figura 16- Scatter e Boxplot da Entropia Espectral

Na análise do gráfico 3D: Máximo Espetral, Entropia Espectral e SEF observamos uma acumulação significativa de pontos vermelhos, representando o dígito 6, em regiões com elevados valores de entropia espectral, baixos valores de máximo das amplitudes e valores altos de SEF. Estas características destacam a utilidade do gráfico 3D na diferenciação precisa dos dígitos.




Figura 17- Gráfico 3D com Máximo Espetral, Entropia Espectral e SEF

Ponto 9

Valores testados:

Pré-Processamento do sinal vs. Pós Processamento do sinal




Figura 18- Espectrograma Pré-processamento




Figura 19- Espectrograma Pós-processamento do sinal

Efeito da alteração do nº de amostras por janela




Figura 20- Espectrograma com alteração de amostras por janela




Figura 21- Espectrograma com alteração de amostras por janela

Espectrograma Janela Predefinida

largura da janela de análise em $s = 0.064$
 superposição das janelas em $s = 0.032$;
 nº de amostras na janela = 3070;
 nº de amostras sobrepostas na janela =

Espectrograma Janela Predefinida

largura da janela de análise em $s = 0.064$
 superposição das janelas em $s = 0.032$;
 nº de amostras na janela = 1024;
 nº de amostras sobrepostas na janela = 128;

Efeito da sobreposição das janelas




Figura 22- Espectrograma com diferentes sobreposições das janelas




Figura 22- Espectrograma com efeito diferentes sobreposições das janelas

Espectrograma Janela Predefinida

largura da janela de análise em $s = 0.064$
 superposição das janelas em $s = 0.032$;
 nº de amostras na janela = 512;
 nº de amostras sobrepostas na janela = 100;

Espectrograma Janela Predefinida

largura da janela de análise em $s = 0.064$
 superposição das janelas em $s = 0.008$;
 nº de amostras na janela = 512;
 nº de amostras sobrepostas na janela = 100;

Efeito da Largura da janela




Figura 23-Espectrograma com diferente largura das janelas




Figura 24-Espectrograma com diferente largura das janelas

Espectrograma Janela Predefinida

largura da janela de análise em $s = 0.950$;
 superposição das janelas em $s = 0.032$;
 nº de amostras na janela = 512;
 nº de amostras sobrepostas na janela = 128;

Espectrograma Janela Predefinida

largura da janela de análise em $s = 0.008$;
 superposição das janelas em $s = 0.032$;
 nº de amostras na janela = 512;
 nº de amostras sobrepostas na janela = 128;

→ Conclusões

Através da comparação dos gráficos “spectrogram” para o pré-processamento e pós-processamento do sinal é perceptível a existência de uma faixa azul-escura na representação do espectrograma que resulta de na fase de processamento do sinal ter sido removido o ruído e adicionados 0's no fim do sinal com vista a normalizar o mesmo.

Analisando as figuras acima é perceptível o efeito da variação do valor para o número de amostras na janela, por um lado o facto de existir um maior número de amostras por janela leva a que exista uma melhor resolução par a frequência, na medida em que existe um maior número de pontos disponíveis para calcular a Transformada de Fourier. Por outro lado, um maior número de amostras afeta a janela de tempo, na medida em que pode levar a perda de detalhes que tenham lugar num período reduzido.

No contexto da sobreposição de janelas quanto menor o valor mais fácil é de captar variações mais bruscas de magnitude ao longo do tempo, em sentido contrário quanto maior for este valor mais suave será a transição entre as janelas.

Relativamente ao efeito do valor para a sobreposição de janelas, quanto maior for o valor maior vai ser a resolução espectral devido a existir mais informações disponíveis para calcular o espectro. No entanto o aumento do número de amostras sobrepostas

leva também a uma suavização do espectro o que pode levar à perda de detalhes no mesmo.

Ponto 10

Para o cálculo das características e de forma a tirar partido da função “*spectrogram*”, calculou-se a magnitude máxima para cada coluna (janela temporal) e armazenou-se estes valores no array `max_magnitude`. Este é o array que posteriormente vai ser aplicado para a obtenção das features.

No nosso estudo calculámos **potência total, zero crossing, potência média e picos máximos**:

→ Potência Total

A potência total é uma medida importante da intensidade do sinal de áudio, que indica a quantidade de energia que está presente no sinal. A potência total é calculada somando-se o quadrado das magnitudes máximas ao longo de cada coluna (janela temporal) do espectrograma. Estes valores são armazenados no array `max_magnitude` e guardados na variável `total_power_stft` para cada amostra de áudio.

→ Zero Crossing Rate

A taxa de zero crossing é utilizada para caracterizar propriedades de ondas sonoras, especialmente para fazer o reconhecimento de fala e música. É útil para distinguir entre diferentes tipos de sinais de áudio. Por exemplo, sinais de música tendem a ter uma taxa de zero crossing mais alta do que sinais de fala, devido à natureza das formas de onda, enquanto na música, ela pode refletir características rítmicas e de timbre.

A taxa de zero crossing é calculada utilizando a função `zeroCrossingRate()` aplicada ao sinal de áudio `y`. Esta função conta o número de vezes que o sinal cruza o eixo horizontal (zero) e normaliza pela duração total do sinal.

→ Potência Média

A potência média fornece uma medida da intensidade média do sinal ao longo do tempo. Permite avaliar a uniformidade da intensidade ao longo do sinal. Pode ser útil na deteção de mudanças de volume ou na identificação de partes do sinal com diferentes níveis de intensidade.

A potência média total é calculada dividindo a potência total pelo número de janelas de tempo no espectrograma.

→ Picos Máximos

Os picos máximos indicam áreas de alta amplitude no sinal de áudio. Permite identificar características salientes no sinal. Por exemplo, picos máximos podem corresponder a transições entre fonemas¹.

Os picos máximos são calculados com a função `findpeaks()` aplicada às magnitudes máximas de cada coluna do espectrograma. O número de picos é então contado e armazenado na variável `total_peaks_stft` para cada amostra de áudio.

O uso do espectrograma permite-nos visualizar como é que a energia está distribuída nas diferentes frequências nos intervalos de tempo discretos, enquanto o cálculo da magnitude máxima em cada janela temporal fornece a medida representativa da intensidade do sinal em cada intervalo de tempo. Optou-se pela utilização da magnitude máxima em detrimento da magnitude média devido ao facto de a média ser facilmente influenciável pela existência de outliers o que poderia por em causa a fiabilidade dos dados.

No ponto que se segue discriminamos os resultados obtidos, assim como a explicação de cada *plot*.

Ponto 11

As características que calculámos no ponto anterior foram apresentadas em plots, de maneira a conseguir analisar e identificar as três que se destacam como melhores discriminadores.

Através da análise do gráfico da Potência Total e da Potência Média por Janela, podemos concluir que são ambas características interessantes para a distinção dos dígitos 2, 5, 6 e 8 na medida em que estes dígitos estão compreendidos entre valores únicos, sendo claro que o dígito 8 é o que atinge menores valores, seguido do 5 e 6 cada um no seu respetivo intervalo de valores. Em sentido contrário o dígito 2 afirma-se como sendo o dígito que atinge os maiores valores de Potência Total. Os restantes dígitos encontram-se em intervalos de valores muito semelhantes não sendo por isso possível distingui-los utilizando estas características.




Figura 26- Scatter e Boxplot da Potencia Total

¹ Fonemas- qualquer som articulado.




Figura 27- Scatter e Boxplot da Potência Média

Em relação ao Zero Crossing Rate concluímos que o dígito 6 apresenta uma taxa mais elevada em comparação com os outros dígitos, indicando uma maior variabilidade nas mudanças de polaridade do sinal de áudio. Em seguida, os dígitos 7, 3, 5, 8, 0 e 9 exibem taxas de zero crossing mais moderadas, sugerindo uma menor flutuação na polaridade do sinal. Por outro lado, os dígitos 1, 2, 4 e 9 têm taxas de zero crossing mais baixas, indicando uma estabilidade maior na polaridade do sinal. Por exemplo, dígitos como 1 e 9 que exibem taxas de zero crossing mais baixas devido à sua natureza mais contínua, traduzindo-se em pronúncias mais prolongadas e constantes.

Ao observar a dispersão dos pontos em cada dígito, podemos notar que os dígitos 0, 3, 5 e 6 apresentam pontos mais dispersos, o que significa uma maior variação na taxa dentro do próprio dígito. Esta dispersão significa que podem apresentar uma maior diversidade na estrutura temporal do som, dificultando um pouco a distinção do dígito. Por outro lado, os dígitos 1, 2, 4, 7, 8 e 9 mostram pontos mais concentrados, indicando uma consistência maior na taxa de zero crossing.

Podemos concluir que se trata de uma boa característica diferenciadora de dígitos na medida em que demonstra uma evidente dispersão de valores entre dígitos, e acaba por ser uma característica que complementa as características anteriormente calculadas.




Figura 28- Scatter e Boxplot do Zero Crossing Rate

Analisando os gráficos respetivos à característica dos Picos Máximos, concluímos que não é uma característica tão diferenciativa como as anteriores na medida em que existem intervalos de valores atingidos que são partilhados por muitos dígitos.




Figura 29- Scatter e Boxplot dos Picos Máximos

O scatterplot seguinte é um plot 3D, que reúne as três melhores características apresentadas no ponto 10. Podemos reparar na diferenciação espacial do dígito 7 em relação aos outros dígitos. Os pontos dos dígitos 6 e 9 encontram-se reunidos, o que ajuda na identificação dos dígitos. Há outros dígitos que estão mais dispersos, no entanto, com a ajuda das outras duas características, conseguimos identificar intervalos de valores aos quais pertencem cada um dos dígitos. Por esta razão, estas foram as três características que consideramos como sendo as melhores.




Figura 30- Scatterplot 3D- Zero Crossing vs. Potência Média vs. Potência Total

Neste plot 3D são apresentadas três características: zero crossing rate, potência média e os picos máximos. Este plot foi utilizado para comparar com o plot anterior (figura 30), de maneira a perceber a diferença das características na distinção dos dígitos.

Embora o dígito 7 seja igualmente identificável, os restantes dígitos não têm valores tão discriminatórios. Conseguimos por isso perceber que não seria a melhor combinação de características para identificar os dígitos, optando pelas três anteriores: potência total, potência média e zero crossing rate.




Figura 31-Scatterplot 3D- Zero Crossing vs. Potência Média vs. Picos Máximos

Ponto 12

A eficácia desta tarefa depende significativamente da qualidade e pertinência das características extraídas dos sinais. Características são parâmetros ou atributos derivados dos sinais que ajudam a distinguir entre diferentes classes (neste caso, dígitos). Para melhorar a precisão da classificação, é crucial selecionar características que capturem de forma eficaz as variações e particularidades dos dados. Neste estudo, selecionamos seis características das nove obtidas anteriormente, cada uma representando diferentes domínios de análise do sinal: temporal, frequência e tempo-frequência. As características, explicadas nos pontos anteriores, são:




Figura 32- Boxplot do Zero Crossing




Figura 33- Boxplot do Total Power STFT

Total Peaks STFT




Figura 34- Boxplot de Total Peaks STFT

SEF (Spectral Edge Frequency)




Figura 35- Boxplot do SEF

Spectral Entropy




Figura 36- Boxplot da Spectral Entropy

Desvio Padrão




Figura 37- Boxplot do Desvio Padrão

Para além dos boxplots apresentados nas figuras anteriores, decidimos fazer scatter plots com a combinação de todas as características duas a duas. A análise dos scatter plots revelou-se crucial para a compreensão das relações entre as características e para a definição de regras de decisão eficientes. Ao observar as combinações de características duas a duas, conseguimos identificar padrões e correlações que não seriam evidentes de outra forma. Este processo permitiu-nos seleccionar as características mais relevantes e definir regras de decisão, visando melhorar a separação e a classificação dos dígitos.




Figura 38- Scatter plot Total power STFT vs. Total Peaks STFT




Figura 39- Scatter Plot Total Power STFT vs. Desvio Padrão




Figura 40- Scatter Plot Total Power STFT vs. SEF




Figura 41- Scatter Plot Total Power STFT vs. Spectral Entropy




Figura 42- Scatter plot Zero Crossing vs. SEF




Figura 43- Scatter Plot Zero Crossing vs. Desvio Padrão




Figura 44- Scatter Plot Zero Crossing vs. Total Power STFT




Figura 45- Scatter Plot Zero Crossing vs Total Peaks STFT




Figura 46- Scatter Plot Zero Crossing vs. Spectral Entropy




Figura 47- Scatter Plot Total Peaks STFT vs. Desvio Padrão




Figura 485- Scatter Plot Total Peaks STFT vs. Spectral Entropy




Figura49 5- Scatter Plot Total Peaks STFT vs. SEF




Figura 50- Scatter Plot SEF vs. Desvio Padrão




Figura 51- Scatter Plot SEF vs. Spectral Entropy




Figura 52- Scatter Plot Spectral Entropy vs. Desvio Padrão

Com base nessas observações, foi possível desenvolver um conjunto de regras de decisão que maximiza a diferenciação entre os dígitos.

Ponto 13

Para o calcular a percentagem de acertos utilizou-se a função `calculateAccuracy`: Primeiro, a função verifica se ambos os vetores têm o mesmo tamanho, emitindo um erro caso contrário. De seguida, é inicializado um contador de número corretamente adivinhados a zero. A função percorre cada dígito nos vetores, incrementando o contador sempre que um dígito adivinhado coincide com o dígito real correspondente. Finalmente, a função calcula a precisão como a percentagem de acertos, dividindo o número de acertos pelo comprimento do vetor de dígitos reais e multiplicando por 100.

Ao analisarmos o array que contém os dígitos adivinhados no `Workspace`, concluímos que as características utilizadas para a distinção foram bem-sucedidas para a identificação dos dígitos: 9, 8, 7, 6, 5 e 4 dado que para estes dígitos a maioria dos dígitos adivinhados correspondem ao dígito real. No entanto as características utilizadas para a diferenciação dos dígitos não permitem uma clara distinção entre os primeiros dígitos (0, 1, 2 e 3) o que resulta numa diminuição percentagem de acertos.

Fatores como o sotaque, a pronúncia, a dicção, a velocidade da fala e a qualidade do instrumento de captação de som promovem a existência de outliers que acabam também por interferir de forma negativa e prejudicar a diferenciação de dígitos.

No entanto consideramos o valor obtido 58.4% para a percentagem de acertos, um valor razoável devido à elevada eficácia de acertos para a maioria dos dígitos que, no entanto, é prejudicada devido à dificuldade de distinguir os primeiros dígitos.

Ponto 14

Relativamente ao conjunto total de características através da análise dos gráficos exibidos no ponto 12, é possível concluir que as 3 características que fornecem maior informação e que permitem uma maior diferenciação entre dígitos são: Zero Crossing Rate, Spectral Entropy e Spectral Edge Frequency. Na figura a seguir apresentamos o gráfico 3D com estas características.




Figura 53- Scatter Plot 3D




Figura 546-Scatter Plot 3D




Figura 55-Scatter Plot 3D

Conclusão

Este projeto abordou a análise de sinais de áudio para o reconhecimento de dígitos, aplicando técnicas nos domínios do tempo e da frequência. O objetivo foi identificar características distintivas que permitissem a discriminação eficaz entre os dígitos de 0 a 9.

Primeiramente, a fase de aquisição e pré-processamento dos sinais foi crucial para garantir a uniformidade dos dados, removendo silêncios iniciais e normalizando amplitudes. Isto permitiu uma base sólida para a análise subsequente. No domínio do tempo, características como energia, amplitude e variações ao longo do tempo foram exploradas e visualizadas graficamente, proporcionando uma primeira abordagem para a identificação dos dígitos.

No domínio da frequência, a análise espectral foi aprofundada através do cálculo do espectro de amplitude mediano e dos quartis. A comparação de diferentes janelas mostrou como as escolhas da parametrização podem afetar a resolução e a qualidade da discriminação dos sinais.

Adicionalmente, a análise tempo-frequência através da STFT (Short-Time Fourier Transform) revelou-se fundamental para perceber a evolução das características espectrais ao longo do tempo.

Em todas as etapas, a representação gráfica das características extraídas foi essencial para identificar as melhores características discriminantes.

Em conclusão, este projeto forneceu uma abordagem abrangente para a análise e reconhecimento de dígitos de áudio, destacando a importância do pré-processamento dos dados, a seleção criteriosa das características e a aplicação de técnicas analíticas avançadas. Os resultados obtidos estabelecem uma base sólida para futuras pesquisas e aplicações em reconhecimento de voz e outras áreas relacionadas à análise de sinais.